Курс по предмету «Структуры данных» Сортировка слиянием во внешней памяти, 27 января 2018 года

Сортировка слиянием во внешней памяти

Филиппов Дмитрий, М4138

Исходный код сортировки можно найти по адресу: https://github.com/DimaPhil/external-merge-sort.

Описание задачи

В задаче требуется реализовать сортировку данных, которые не помещаются в оперативную память и требуют сохранения на жесткий диск компьютера. Сортировать можно разные объекты, но мы для упрощения рассмотрим здесь сортировку целых чисел и строк (однако с поддержкой сортировки и других объектов).

Детали реализации

Представим нашу задачу немного по-другому. Будем рассматривать данные как набор файлов, где размер каждого файла не очень большой (влезает в оперативную память). Тогда алгоритм сортировки будет выглядеть следующим образом: отсортируем каждый файл отдельно (это можно сделать in-memory), а затем смержим все файлы в один большой - это можно сделать n указателями с дописыванием в итоговый файл.

В классе utils/SortAndMergeUtils.scala представлена основная логика алгоритма — функция sortAndMergeFiles получает на вход список файлов, которые надо отсортировать и смержить, а делает всю работу. В этой функции также добавлена логика разбиения файла на более маленькие, если его размер слишком большой — это сделано для того, чтобы код работал даже для списка файлов с большим объемом данных во избежание ручной работы, а также, чтобы алгоритм масштабировался под оставшееся количество оперативной памяти.

Для чтения и записи в файл используются классы ReaderBuilder, WriterBuilder, которые являются фабриками для ридеров и райтеров. Для данной задачи была использована одна из возможных реализация Reader и Writer-TextReader и TextWriter, которые используют TextSerializer для чтения и записи данных. TextSerializer- обычный интерфейс с двумя методами serialize и deserialize.

Вместе с этими интерфейсами реализация работы с файлами становится очень простой. Еще большой упрощает жизнь то, что Reader реализует интерфейс Iterator, что позволяет работать с файлом как с обычным потоком данных.

Таким образом, алгоритм выглядит следующим образом:

- Разбить большие файлы на более маленькие, которые помещаются в оперативную память (оставшуюся);
- Каждый маленький файл отсортировать
- Начать сливать файлы
 - Используем метод указателей
 - На каждой итерации сливаем группы из 32 файлов в один
 - Продолжаем, уменьшив тем самым количество файлов в 32 раза
- В результате получаем один файл, содержащий все данные ответ

Тестирование

Для тестирования нашей реализации были проведены два набора тестов: первый — для строк, второй — для целых чисел. В каждом наборе тестов мы запускает 10^4 подтестов, в каждом из которых сортируем данные из 100 небольших файлов. После получения результата, сравниваем его с полученным руками (с сортировкой в оперативной памяти).

Также был проведен тест сортировки большого файла на $11\Gamma 6$ — но здесь после получения результата мы можем только проверить, что результат отсортирован. Однако, прохождение предыдущих тестов дает право утверждать, что все работает :)

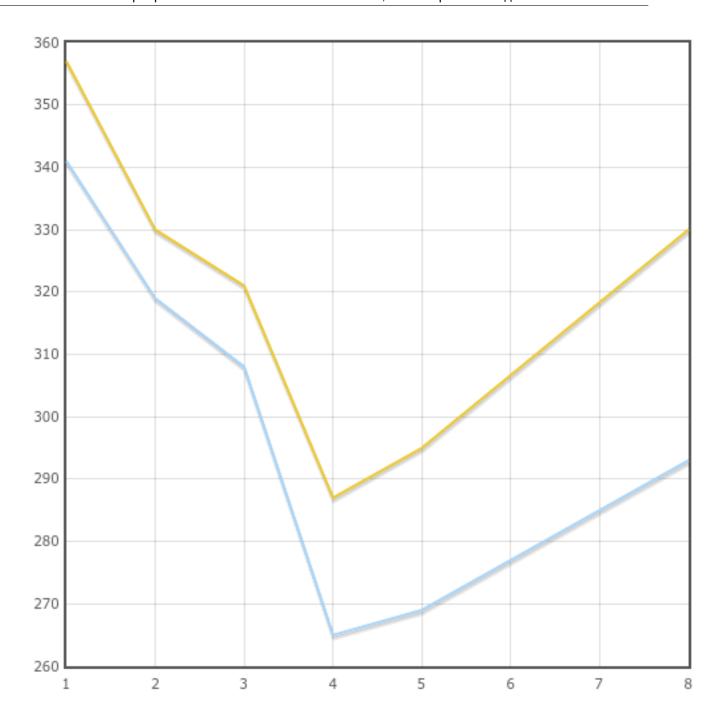
Курс по предмету «Структуры данных» Сортировка слиянием во внешней памяти, 27 января 2018 года

Время работы

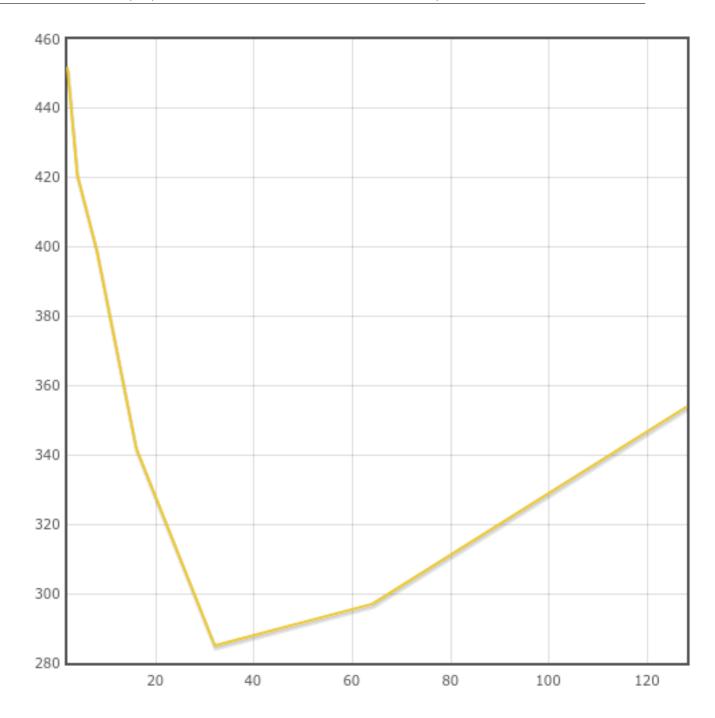
Для подсчета времени работы были проведены следующие тесты:

- Мердж 10^4 неотсортированных файлов по 10^5 чисел работает в среднем за 240 секунд;
- Мердж 10^4 неотсортированных файлов по 10^4 строк по 10 символов работает в среднем за 310 секунд;
- Сортировка одного большого файла на 10^9 чисел (11 Γ б) около 40 минут.

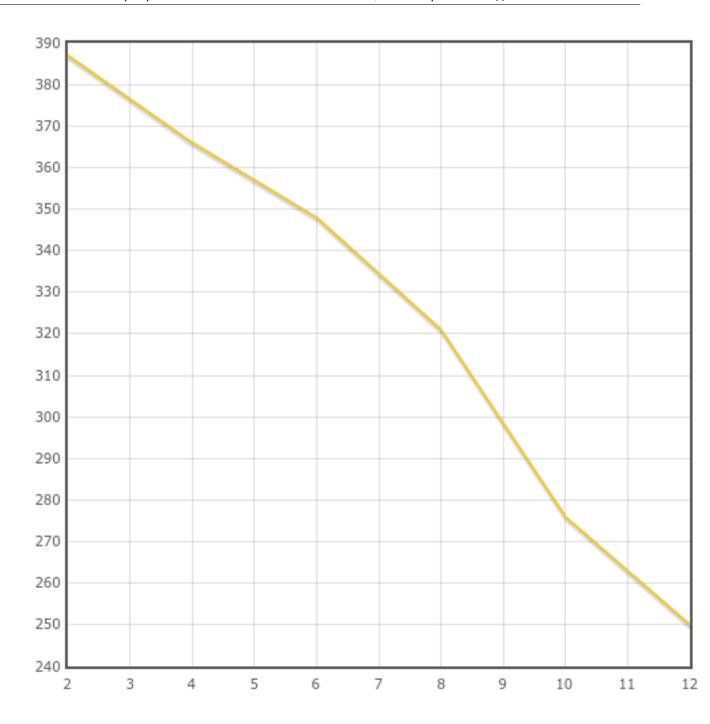
Приведем дополнительную информацию, показывающую зависимости некоторых величин: Зависимость времени работы (сортировки 10^4 файлов по 10^5 чисел или 10^4 строк по 10 символов в каждом) в зависимости от количества чисел в одном файле (то есть чисел/строк, которые будут сортироваться в оперативной памяти). Количество чисел вычисляется по формуле $\min(10^7, freeMemory()/4/divisor)$, где divisor— параметр на оси графика. В рамках тестирования свободная оперативная память (freeMemory) была примерно равна 3Γ б.



Здесь синией линией нарисован график для строк, желтой — для целых чисел. Зависимость времени работы от количества сливаемых файлов (в основном коде использовали 32, время замерялось на тесте из 10^4 файлов по 10^5 чисел, а также с divisor=4):



Зависимость времени работы от свободной оперативной памяти (результаты могут быть неточны, потому что Runtime.getRuntime.freeMemory в Java может выдавать не совсем точные результаты из-за скачков памяти, а также размер свободной оперативной памяти может немного меняться в зависимости от других процессов):



Возможно, результаты не идеальны, но по-моему вполне неплохие :)