

Сортировка слиянием во внешней памяти

Филиппов Дмитрий, M4138

Исходный код сортировки можно найти по адресу: <https://github.com/DimaPhil/external-merge-sort>.

Описание задачи

В задаче требуется реализовать сортировку данных, которые не помещаются в оперативную память и требуют сохранения на жесткий диск компьютера. Сортировать можно разные объекты, но мы для упрощения рассмотрим здесь сортировку целых чисел и строк (однако с поддержкой сортировки и других объектов).

Детали реализации

Представим нашу задачу немного по-другому. Будем рассматривать данные как набор файлов, где размер каждого файла не очень большой (влезает в оперативную память). Тогда алгоритм сортировки будет выглядеть следующим образом: отсортируем каждый файл отдельно (это можно сделать in-мемори), а затем смержим все файлы в один большой - это можно сделать n указателями с дописыванием в итоговый файл.

В классе *utils/SortAndMergeUtils.scala* представлена основная логика алгоритма — функция *sortAndMergeFiles* получает на вход список файлов, которые надо отсортировать и смержить, а делает всю работу. В этой функции также добавлена логика разбиения файла на более маленькие, если его размер слишком большой — это сделано для того, чтобы код работал даже для списка файлов с большим объемом данных во избежание ручной работы, а также, чтобы алгоритм масштабировался под оставшееся количество оперативной памяти.

Для чтения и записи в файл используются классы *ReaderBuilder*, *WriterBuilder*, которые являются фабриками для ридеров и райтеров. Для данной задачи была использована одна из возможных реализация *Reader* и *Writer* — *TextReader* и *TextWriter*, которые используют *TextSerializer* для чтения и записи данных. *TextSerializer* — обычный интерфейс с двумя методами *serialize* и *deserialize*.

Вместе с этими интерфейсами реализация работы с файлами становится очень простой. Еще большой упрощает жизнь то, что *Reader* реализует интерфейс *Iterator*, что позволяет работать с файлом как с обычным потоком данных.

Тестирование

Для тестирования нашей реализации были проведены два набора тестов: первый — для строк, второй — для целых чисел. В каждом наборе тестов мы запускаем 10^4 подтестов, в каждом из которых сортируем данные из 100 небольших файлов. После получения результата, сравниваем его с полученным руками (с сортировкой в оперативной памяти).

Также был проведен тест сортировки большого файла на 11Гб — но здесь после получения результата мы можем только проверить, что результат отсортирован. Однако, прохождение предыдущих тестов дает право утверждать, что все работает :)

Время работы

Для подсчета времени работы были проведены следующие тесты:

- Мердж 10^4 неотсортированных файлов по 10^5 чисел — работает в среднем за 240 секунд;
- Мердж 10^4 неотсортированных файлов по 10^4 строк по 10 символов — работает в среднем за 310 секунд;
- Сортировка одного большого файла на 10^9 чисел (11 Гб) — около 40 минут.

Возможно, результаты не идеальны, но по-моему вполне неплохие :)